

基于 3D U-Net 与三重注意力机制的短期气温预测模型 项目文档

作者: Boyu Yang 学号: PB25000215

2026 年 5 月

目录

1	项目背景与目标	2
2	设计方案	3
2.1	整体流程	3
2.2	模块结构	3
2.3	核心类与方法	4
2.3.1	ClimateDataset	4
2.3.2	ClimateUNet	4
2.3.3	ConvBlock / EncoderBlock / DecoderBlock	4
2.3.4	ChannelAttention3D / SpatialAttention3D / TemporalAttention3D	4
2.3.5	TimeEmbedding / TerrainEmbedding	4
2.3.6	Animator	5
3	创新性	6
3.1	3D U-Net 与三重注意力机制的融合	6
3.2	显式时间编码捕获季节与昼夜模式	6
3.3	地形数据融合增强地理条件建模	6
3.4	梯度累积实现大型 3D 模型的高效训练	6
4	运行方法和参数设置	7
4.1	环境准备	7
4.2	执行流程	7
4.3	关键参数说明	7
5	学习心得和收获	8
5.1	课程学习总结	8
5.2	项目实践收获	8
5.3	未来展望	8

第一章 项目背景与目标

气候变化是当今世界面临的重大挑战之一，准确的气候预测对于农业生产、环境保护、灾害预警等领域具有重要意义。ERA5-Land 是欧洲中期天气预报中心 (ECMWF) 提供的高分辨率陆地再分析数据集，包含了丰富的历史气候变量记录，为气候研究和预测提供了重要的数据基础 [5, 1]。

传统的气候预测方法主要依赖于物理模型和气象模拟仿真技术，虽然在一定程度上能够提供准确的预测，但计算成本高昂，且在某些复杂地理环境下的表现仍有提升空间。近年来，深度学习技术，特别是卷积神经网络 (CNN) 在气象领域的应用取得了显著进展。然而，现有研究大多使用 2D 卷积处理空间数据，忽略了气候变量在时间维度上的连续演变特征。

本项目的核心目标是开发一个基于 3D U-Net 架构的气候预测系统 [6, 9]，结合通道注意力、空间注意力和时间注意力的三重注意力机制 [8, 2, 7]，充分利用 ERA5-Land 数据集的时空特征，实现对未来 12 小时的地表温度等 12 种气候变量的预测。数据包含温度、风速、辐射、气压、土壤温度和土壤湿度等多类变量，能够全面刻画近地表气候状态。通过融合地形数据（海拔高度）作为辅助输入，提升模型在复杂地形区域的预测精度。

具体来说，本项目旨在实现以下目标：

- 构建完整的数据处理 Pipeline，支持 ERA5-Land 数据的自动下载、预处理
- 设计并实现基于 3D U-Net 的深度学习模型，引入三重注意力机制（通道注意力 + 空间注意力 + 时间注意力）增强特征提取能力
- 同时使用时间编码和地形编码作为条件输入，提升模型对时序信息和地理信息的建模能力
- 实现高效的训练流程，支持梯度累积、断点续训和实时损失可视化
- 提供全面的模型评估和可视化工具，支持预测结果的分析与展示

第二章 设计方案

2.1 整体流程

本项目的整体流程包括数据下载与预处理、模型训练与验证、模型评估与可视化三个阶段。具体而言，首先通过 `installer.py` 从 CDS API 下载 ERA5-Land 数据，然后使用 `converter.py` 将 NetCDF 格式数据转换为 PyTorch 张量；接着通过 `scripts/train.py` 进行模型训练，训练过程中支持梯度累积、断点续训等功能；最后通过 `scripts/test_model.py` 评估模型性能，并使用 `demos/climate_visualizer.py` 进行结果可视化。

2.2 模块结构

表 1: 模块结构说明

模块名	功能描述
<code>installer.py</code>	数据下载模块，负责从 CDS API 获取 ERA5-Land 数据
<code>converter.py</code>	数据转换模块，将 NetCDF 格式转换为 PyTorch 张量格式
<code>src/models/attention.py</code>	三重注意力机制模块，包含 Channel, Spatial, Temporal 三种维度的注意力机制
<code>src/models/blocks.py</code>	模型块定义模块，包含 ConvBlock、EncoderBlock、DecoderBlock，下采样和上采样等模型块
<code>src/models/embedding.py</code>	嵌入层模块，包含 Positional 位置嵌入，Time 时间嵌入，Terrain 地形嵌入
<code>src/models/unet.py</code>	整体模型拼接模块，将各种子模块拼接起来，实现 3D Climate Unet
<code>src/dataset.py</code>	数据集模块，实现 ClimateDataset 数据加载和预处理
<code>src/animater.py</code>	可视化工具模块，用于实时显示训练损失
<code>scripts/train.py</code>	训练脚本，包含训练循环、梯度累积、断点续训等功能
<code>scripts/test_model.py</code>	测试脚本，计算预测误差指标
<code>demos/climate_visualizer.py</code>	可视化演示脚本，生成比较图、地形叠加图和预测动画

2.3 核心类与方法

2.3.1 ClimateDataset

ClimateDataset 是数据加载的核心类，负责从转换后的张量文件中读取数据，进行归一化和标准化处理，并按照指定的时间步长构建输入-输出样本对。数据集按时间维度自动划分训练集和测试集（测试集取末尾约 5% 的数据），索引随机打乱以避免时间顺序偏差。数据集包含 12 个气候变量通道（t2m, u10, v10, d2m, skt, ssrd, ssr, sp, stl1, sshf, swvl1, lmlt），以及海拔高度（terrain）作为辅助地形信息。

2.3.2 ClimateUNet

ClimateUNet 是项目的主模型，基于 3D U-Net 架构设计 [6, 9]，整体结构包含编码器和解码器两部分。编码器包含 3 个 EncoderBlock，每个 EncoderBlock 内依次应用时间注意力和空间注意力模块，编码器块之间通过 Downsample3D（步长卷积）进行 2 次下采样；解码器包含 3 个 DecoderBlock，每个 DecoderBlock 内包含通道注意力模块和上采样层。三重注意力机制（时间注意力 + 空间注意力 + 通道注意力）分布在编码器和解码器中，从不同维度增强模型对关键特征的捕捉能力。最后通过输出投影层生成 12 小时步的预测结果。

2.3.3 ConvBlock / EncoderBlock / DecoderBlock

ConvBlock 是基础卷积模块，包含 3D 卷积 (Conv3d)、GroupNorm 组归一化和 SiLU 激活函数。EncoderBlock 包含 ConvBlock、TemporalAttention3D、第二个 ConvBlock 和 SpatialAttention3D 的串联结构。DecoderBlock 包含一个上采样层 (ConvTranspose3d)、ConvBlock、ChannelAttention3D 和第二个 ConvBlock。下采样由独立的 Downsample3D 模块（步长卷积）完成。这种设计保证了特征提取的充分性和信息传递的流畅性。

2.3.4 ChannelAttention3D / SpatialAttention3D / TemporalAttention3D

三重注意力机制是本项目的核心创新点之一。ChannelAttention3D 通过学习通道间的重要性权重，自适应地增强重要特征通道的响应（应用于 DecoderBlock）；SpatialAttention3D 关注空间位置的重要性，突出关键区域的信号（应用于 EncoderBlock）；TemporalAttention3D 捕捉时间维度的依赖关系，强化时序特征的表达（应用于 EncoderBlock）。三个注意力模块分布在编码器和解码器结构中，从不同维度对特征进行重标定，显著提升了模型的代表能力。

2.3.5 TimeEmbedding / TerrainEmbedding

TimeEmbedding 将时间信息（月份、日期、小时）编码为特征向量，使模型能够感知季节和昼夜节律变化。TerrainEmbedding 对海拔高度进行嵌入编码，为模型提供地形先验知识。两种嵌入在编码器特征注入模块中与图像特征融合，实现对模型的条件控制。

2.3.6 Animator

Animator 类用于实时显示训练过程中的损失曲线，支持动态更新多条损失曲线，便于监控训练状态。通过在训练循环中调用 `animator.add(loss)` 可以实时更新图表。预测结果的动画 (GIF) 生成由 `demos/climate_visualizer.py` 中的 `ClimateVisualizer` 类实现。




图 1: ClimateUNet 模型架构示意图。模型输入包含动态地形、静态地形和时序气象数据，通过时间嵌入模块注入时间信息，经编码器-解码器结构提取多尺度时空特征，最终输出 12 小时步的气候预测结果。

第三章 创新性

3.1 3D U-Net 与三重注意力机制的融合

本项目的首要创新点在于将 3D U-Net 架构 [9, 6] 与三重注意力机制（时间注意力 + 空间注意力 + 通道注意力）[8, 2, 7] 相结合，用于气候预测任务。传统的气候预测方法要么使用纯物理模型，要么使用简单的 2D CNN，无法充分建模气候数据的三维时空特征。3D U-Net 通过在编码器和解码器中使用 3D 卷积，能够在空间和时间维度上同时进行特征提取，保留数据的时间连续性和空间相关性。时间注意力和空间注意力嵌入编码器块中、通道注意力嵌入解码器块中，从不同维度增强模型对关键特征的关注能力，形成了一种端到端的时空预测新范式。

3.2 显式时间编码捕获季节与昼夜模式

气候系统具有显著的季节变化和昼夜交替规律。现有方法大多隐式地依赖模型自动学习这些时间模式，但往往需要大量数据和计算资源才能有效捕捉。本项目引入显式的时间编码机制，将月份、日期和小时信息作为条件输入，引导模型更高效地学习时间依赖关系。这种设计不仅加速了模型收敛，还提高了在长时间跨度上的预测稳定性。

3.3 地形数据融合增强地理条件建模

ERA5-Land 数据包含地表温度、风速、辐射、气压、土壤温度、土壤湿度等多类变量，这些变量与地形高度密切相关。例如，海拔越高、温度越低；山脉迎风坡与背风坡的降水量差异显著。现有研究大多只使用气候变量本身进行预测，忽略了地形这一关键因素的影响。本项目创新地将海拔高度作为辅助输入通道，在编码器特征注入模块中与主特征融合，使模型能够感知不同地理位置的差异，从而提升在复杂地形区域的预测性能。

3.4 梯度累积实现大型 3D 模型的高效训练

3D U-Net 模型参数量较大，对 GPU 显存要求较高。在批大小受限的情况下，直接使用小批大小训练会导致梯度估计不稳定、Group Normalization 统计量不准确等问题。本项目实现了梯度累积机制，通过累积多个小批次的梯度后统一更新参数，在不增加显存消耗的条件下实现了较大的有效批大小，确保了训练的稳定性。

第四章 运行方法和参数设置

4.1 环境准备

运行本项目需要 Python 3.8 或以上版本，以及 PyTorch、NumPy、Matplotlib、NetCDF4、cdsapi 等 Python 库。在使用 ERA5-Land 数据前，需要在 ECMWF CDS 官网注册账号并获取 API 密钥，安装并配置 cdsapi 库。

4.2 执行流程

步骤 1: 数据下载 — 运行 `python installer.py` 从 CDS API 下载 ERA5-Land 数据。

步骤 2: 数据转换 — 运行 `python converter.py` 将 NetCDF 格式转换为 PyTorch 张量格式。

步骤 3: 模型训练 — 运行 `python scripts/train.py` 训练模型，支持以下参数：

步骤 4: 模型测试 — 运行 `python scripts/test_model.py` 计算预测误差。

步骤 5: 结果可视化 — 运行 `python demos/climate_visualizer.py` 展示预测结果。

4.3 关键参数说明

表 2: 关键参数说明

参数	说明	默认值
<code>--epochs</code>	总训练轮数	15
<code>--batch-size</code>	每个 Batch 的大小	6
<code>--accumulate-steps</code>	梯度累积步数	10
<code>--resume</code>	断点续训的检查点路径	None

参数效果说明：批大小 (batch-size) 直接影响 GPU 显存消耗。由于本项目的训练在 NVIDIA GeForce RTX 5060 Ti (16GB) 显卡上完成，对于 3D U-Net 这样的模型，在当前数据上训练时，批大小通常设置为 6。梯度累积步数 (accumulate-steps) 用于弥补小批大小带来的梯度估计不稳定性，有效批大小 = `batch_size` × `accumulate-steps`。学习率 (lr) 在 `src/config.py` 中固定为 1×10^{-4} ，实验表明使用 AdamW 优化器 [3, 4] 在此学习率下模型收敛效果较好。

第五章 学习心得和收获

5.1 课程学习总结

通过本课程的学习，我系统掌握了 Python 科学计算的核心知识体系，包括 NumPy 数值计算、Matplotlib 数据可视化、PyTorch 深度学习框架等关键技术。在项目实践中，将理论知识与实际问题相结合，加深了对科学计算方法论的理解。

5.2 项目实践收获

深度学习架构设计：通过设计和实现 3D U-Net 及三重注意力机制，深入理解了深度学习模型的设计原则和技巧。特别是注意力机制在特征融合中的作用，以及编码器-解码器架构处理时空数据时的优势，加深了对深度模型内部机理的认识。

数据处理能力：处理 NetCDF 格式的气象数据，掌握了科学数据的读取、转换、标准化和样本构建流程。学会了如何处理大规模三维时空数据，以及如何在有限内存条件下高效加载和处理数据。

工程实践能力：搭建了完整的项目 Pipeline，从数据获取到模型训练再到结果可视化，锻炼了软件工程方法论和代码组织能力。掌握了使用 Python 构建深度学习项目的流程和规范。

问题解决能力：在项目实施过程中遇到了显存不足、训练不稳定等问题，通过查阅资料和反复实验，找到了梯度累积、Group Normalization 等应对策略，提升了解决实际问题的能力。

5.3 未来展望

本项目虽然取得了一定的成果，但仍有许多可以改进和扩展的方向：引入更多气候变量以进一步丰富输入信息；探索 Transformer 架构在气候预测中的应用潜力；将预测范围扩展到更长的时效（24-72 小时）；与传统的数值天气预报方法进行对比和融合研究；部署模型提供实时的气候预测服务。期待在未来能够将深度学习技术更深入地应用于气象领域，为气候研究和实际应用做出贡献。

参考文献

- [1] Hans Hersbach et al. “The ERA5 Global Reanalysis”. In: *Quarterly Journal of the Royal Meteorological Society* 146.730 (2020), pp. 1999–2049. DOI: [10.1002/qj.3803](https://doi.org/10.1002/qj.3803).
- [2] Jie Hu, Li Shen, and Gang Sun. “Squeeze-and-Excitation Networks”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE Computer Society, 2018, pp. 7132–7141. DOI: [10.1109/CVPR.2018.00745](https://doi.org/10.1109/CVPR.2018.00745).
- [3] Diederik P. Kingma and Jimmy Ba. “Adam: A Method for Stochastic Optimization”. In: *3rd International Conference on Learning Representations, ICLR 2015*. San Diego, CA, USA, 2015.
- [4] Ilya Loshchilov and Frank Hutter. “Decoupled Weight Decay Regularization”. In: *7th International Conference on Learning Representations, ICLR 2019*. New Orleans, LA, USA, 2019.
- [5] Joaquín Muñoz-Sabater et al. “ERA5-Land: A State-of-the-Art Global Reanalysis Dataset for Land Applications”. In: *Earth System Science Data* 13.9 (2021), pp. 4349–4383. DOI: [10.5194/essd-13-4349-2021](https://doi.org/10.5194/essd-13-4349-2021).
- [6] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. “U-net: Convolutional networks for biomedical image segmentation”. In: *International Conference on Medical image computing and computer-assisted intervention*. Springer. 2015, pp. 234–241.
- [7] Ashish Vaswani et al. “Attention Is All You Need”. In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017.
- [8] Sanghyun Woo et al. “CBAM: Convolutional Block Attention Module”. In: *Proceedings of the European Conference on Computer Vision (ECCV)*. Cham: Springer, 2018, pp. 3–19.
- [9] zgün iek zgün et al. “3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation”. In: *Springer, Cham* (2016).